

VAE

Вариационные автокодировщики

Цель

- Познакомится с концептом автокодировщиков, рассмотреть эволюцию данного типа моделей


План

- Задача генеративного обучения
- Вариационные автокодировщики (VAE)
- VQ-VAE и VQ-GAN
- dVAE
- Улучшения VQ-VAE и dVAE

Задача генеративного обучения


Дискриминативные и генеративные модели

Discriminant Model




Оценивают $p(y|x)$
Например $p(cat|image), p(dog|image)$

Generative Model



Оценивают $p(x)$ или $p(x, y)$
Например $p(image)$ или $p(image, cat), p(image, dog)$

Генеративные модели



Генеративные модели

- Дискриминативные модели оценивают $p(y|\bar{x})$
- Генеративные модели оценивают $p(\bar{x}, y)$ или $p(\bar{x})$
- Добиваются они этого, пытаясь приблизить распределение, порождаемое моделью и распределение данных:
$$p_{model}(\bar{x}|\theta) \approx p_{data}(\bar{x})$$
- Поскольку p_{data} определено только на обучающих примерах, то мы хотим чтобы p_{model} на них было максимально

Генеративные модели

- Воспользовавшись методом максимального правдоподобия:

$$\theta^* = \arg_{\theta} \max \prod_{\bar{x} \in D} p_{model}(\bar{x}|\theta) = \arg_{\theta} \max \sum_{\bar{x} \in D} \log p_{model}(\bar{x}|\theta)$$

Генеративные модели

- Другой взгляд на такую оптимизацию – это минимизация KL-дивергенции между распределениями p_{data} (p_d) и p_{model} (p_g):


$$KL(p_d || p_g) = \int p_d(x) \log \frac{p_d(x)}{p_g(x)} dx = - \int p_d(x) \log \frac{p_g(x)}{p_d(x)} dx$$

Генеративные модели


$$\begin{aligned}\theta^* &= \arg_{\theta} \min KL(p_d || p_g) = \arg_{\theta} \min \int p_d(\bar{x}) \log \frac{p_d(\bar{x})}{p_g(\bar{x})} d\bar{x} = \\ &= \arg_{\theta} \min \left[\int p_d(\bar{x}) \log p_d(\bar{x}) dx - \int p_d(\bar{x}) \log p_g(\bar{x}) dx \right] \\ &= \arg_{\theta} \max \left[\int p_d(\bar{x}) \log p_g(\bar{x}) dx \right] = \\ &= \arg_{\theta} \max \sum_n \frac{1}{N} \log p_g(\bar{x}) = \arg_{\theta} \max \sum_{\bar{x} \in D} \log p_g(\bar{x})\end{aligned}$$

- Таким образом, минимизация KL-дивергенции равносильна максимизации правдоподобия!

Таксономия генеративных моделей



Генеративная трилемма




[Tackling the Generative Learning Trilemma with Denoising Diffusion GANs, Arxiv](#)

Вариационные автокодировщики (VAE)


[Auto-Encoding Variational Bayes, Arxiv \(2013\)](#)

Автокодировщик (AE)



Вариационный Автокодировщик

Variational Autoencoder



[Auto-Encoding Variational Bayes, Arxiv \(2013\)](#)

Вариационный Автокодировщик

Что мы оптимизируем?

- VAE пытается оценить правдоподобие $p(x)$ через интегрирование по латентным переменным z :

$$p(x) = \int_z p(x, z) dz = \int_z p(x|z)p(z) dz$$

- Рассмотрим логарифм правдоподобия:

$$\log p(x) = \log \int_z p(x, z) dz = \log \int_z p(x|z)p(z) dz$$

Вариационный Автокодировщик

Что мы оптимизируем?

- Введем $q(z|x)$ - распределение латентных переменных для конкретного x , внесем его в правдоподобие:

$$\begin{aligned}\log p(x) &= \log \int p(x, z) dz = \log \int q(z|x) \frac{p(x, z)}{q(z|x)} dz \\ &= \log \mathbb{E}_{q(z|x)} \left[\frac{p(x, z)}{q(z|x)} \right]\end{aligned}$$

Вариационный Автокодировщик

Что мы оптимизируем?

- Воспользуемся неравенством Йенсена (Jensen's inequality):

$$\log \mathbb{E}_{q(z|x)} \left[\frac{p(x, z)}{q(z|x)} \right] \geq \mathbb{E}_{q(z|x)} \log \left[\frac{p(x, z)}{q(z|x)} \right]$$

$$\mathbb{E}_{q(z|x)} \log \left[\frac{p(x, z)}{q(z|x)} \right] = \int q(z|x) \log \frac{p(x, z)}{q(z|x)} dz =$$

$$= \int q(z|x) \log \frac{p(x|z)p(z)}{q(z|x)} dz =$$

Вариационный Автокодировщик

Что мы оптимизируем?

$$= \int q(z|x) \log \frac{p(x|z)p(z)}{q(z|x)} dz$$

$$= \int q(z|x) \log p(x|z) dz + \int q(z|x) \log p(z) dz - \int q(z|x) \log q(z|x) dz$$

$$= \int q(z|x) \log p(x|z) dz - \int q(z|x) \log \frac{q(z|x)}{p(z)} dz =$$

Вариационный Автокодировщик

Что мы оптимизируем?

$$\begin{aligned} &= \int q(z|x) \log p(x|z) - \int q(z|x) \log \frac{q(z|x)}{p(z)} dz \\ &= \mathbb{E}_{q(z|x)} \log p(x|z) - KL(q(z|x) || p(z)) \end{aligned}$$

- Поскольку наша задача – максимизировать правдоподобие (или его логарифм), то мы хотим максимизировать первый член, попутно минимизируя второй
- Зачастую в оптимизации мы переходим к минимизации отрицательного значения правдоподобия

Вариационный Автокодировщик

Что мы оптимизируем?

- Таким образом, общая функция потерь для VAE следующая:
$$-\mathbb{E}_{q(z|x)} \log p(x|z) + KL(q(z|x) || p(z))$$
- где $q(z|x)$ - “энкодер”, $p(x|z)$ - “декодер”, а $p(z)$ - априорное распределение на латентные переменные (обычно берем $N(0,1)$)

Вариационный Автокодировщик

Что мы оптимизируем?

- Обычно предполагается, что:

$$p(x|z) = N(\mu_\theta(x), \sigma_\theta(x)) = N(\hat{x}, \sigma^2 I)$$
$$-\log p(x|z) = -\log \frac{1}{\sqrt{2\pi\sigma}} - \frac{(x - \hat{x})^2}{2\sigma^2}$$
$$(x - \hat{x})^2 \rightarrow \min_{\theta}$$

Вариационный Автокодировщик

Что мы оптимизируем?

$$KL(\pi||p) = \int \pi(x) \log \frac{\pi(x)}{p(x)} dx$$



$$KL \left(N(\mu_1, \sigma_1^2) || N(\mu_2, \sigma_2^2) \right) = \log \frac{\sigma_2}{\sigma_1} + \frac{\sigma_1^2 + (\mu_1 - \mu_2)^2}{2\sigma_2^2} - \frac{1}{2}$$

$$KL \left(N(0, I) || N(\mu_\theta, \sigma_\theta^2) \right) = \log \frac{\sigma_\theta}{1} + \frac{1^2 + (0 - \mu_\theta)^2}{2\sigma_\theta^2} - \frac{1}{2}$$

Вариационный Автокодировщик

Проблемы KL-дивергенции

$$KL_{forward}(\pi||p) = \int \pi(x) \log \frac{\pi(x)}{p(x)} dx \quad KL_{reverse}(p||\pi) = \int p(x) \log \frac{p(x)}{\pi(x)} dx$$



Вариационный Автокодировщик

Reparametrization trick

- Нам остается лишь понять, как сделать так, чтобы градиенты текли через процесс сэмплирования

$$z = N(\mu_{\theta}, \sigma_{\theta}^2)$$

- Воспользовавшись свойством нормального распределения, получим:

$$\epsilon \sim N(0, I)$$

$$z = \mu_{\theta} + \sigma_{\theta} * \epsilon$$

- Данный подход называется трюком репараметризации (reparametrization trick)

Вариационный Автокодировщик

Итоговая функция потерь

- Итого, итоговый лосс выглядит следующим образом:


$$L = MSE(x, \hat{x}) + \lambda KL \left(N(\mu_\theta, \sigma_\theta^2) \parallel N(0, I) \right)$$

где

$$KL \left(N(\mu_\theta, \sigma_\theta^2) \parallel N(0, I) \right) = \frac{1}{2} (\sigma_\theta^2 + \mu_\theta - \log \sigma_1^2)$$

Вариационный Автокодировщик


Латентное пространство




Вариационный Автокодировщик

Латентное пространство


Only reconstruction loss



Only KL divergence




Combination



Состязательный Автокодировщик


Adversarial Autoencoder



[Adversarial Autoencoders, Arxiv \(2015\)](#)


Vector Quantized Variational Autoencoder (VQVAE)

VQVAE




[Neural Discrete Representation Learning, Arxiv \(2017\)](#)


VQVAE



VQVAE




VQVAE



VQVAE


$$z_q = KNN(z_e, codebook)$$
$$z_q = z_e + (z_q - z_e).detach()$$

VQVAE




$$z_q = \text{KNN}(z_e, \text{codebook})$$
$$\mathcal{L} = \text{MSE}(x, x') + \text{MSE}(\text{sg}[z_e], e)$$

VQVAE





VQVAE




$$\mathcal{L} = MSE(x, x') + MSE(z_e, e)$$

VQVAE Inference



[Decoder-Only Transformers: The Workhorse of Generative LLMs, Substack](#)

VQGAN





dVAE

[Categorical Reparametrization with Gumbel-Softmax, Arxiv](#)


dVAE (Gumbel-VQ)

Проблема утилизации векторов кодабука

VQ-GAN




dVAE



[Categorical Reparametrization with Gumbel-Softmax, Arxiv](#)


dVAE

Gumbel-Softmax




dVAE

Gumbel-Softmax



dVAE (Gumbel-VQ)

Утилизация векторов кодбука



Улучшение VQ-VAE и dVAE

[Regularized Vector Quantization for Tokenized Image Synthesis, Arxiv](#)


Улучшение VQ-VAE и dVAE

Регуляризация кодбука и выходов энкодера

- Было замечено, что добавление L2 регуляризации на вектора кодбука и выходы энкодера дает существенный прирост в стабильности обучения и сильно повышает утилизацию векторов

Улучшение VQ-VAE и dVAE

Регуляризация кодбука и выходов энкодера



Выводы

- Вспомнили, в чем заключается задача генеративного обучения
- Рассмотрели основные подходы с точки зрения VAE (VAE / VQ-VAE, VQGAN, dVAE)
- Рассмотрели набор улучшений, которые позволяют этим моделям работать лучше

Полезные ссылки

- [Блог Lilian Weng про VAE](#)
- [Статья о VAE](#), [Статья о VQ-VAE](#), [Статья о VQ-GAN](#)
- [Применение VQ-GAN для задачи восстановления лиц](#)
- [Обучение MoVQGAN от Сбера](#)
- [Сжатие изображений с помощью VAE от Stable Diffusion](#)